

Курс «Продуктовые метрики» • Лекция 3

Метрики в А/В-тестировании

Про что говорили на прошлой неделе

Эксперименты двигают инпуты, а не главную метрику компании

Лекция 2: главная метрика компании — output. Сдвинуть ее напрямую почти невозможно, она растет через input-метрики. Доказать причинность между ними можно при помощи A/B-тестирования

Семинары недели 2: ключевые метрики зависят от модели продукта.

Сегодня разберемся, как выбрать метрики эксперимента на уровне инпутов.

Какой должна быть метрика эксперимента

Измеримая

можно рассчитать из доступных данных

Устойчивая

не реагирует на то, что не связано с воздействием

Объяснимая

изменения можно связать с воздействием

Чувствительная

реагирует на реалистичные размеры эффекта

Как сформировать набор метрик для проведения эксперимента

Роли метрик в эксперименте, влияние системы приоритетов на метрик-сет.

ОЕС и шесть ролей метрик

ОЕС (Overall Evaluation Criterion) — количественная мера, отражающая цель эксперимента. Одно число, по которому принимается решение.

Таргет

метрика успеха: то, ради чего проводится эксперимент

Драйверы

механизм, через который фича помогает сдвинуть таргет — быстрее и чувствительнее, поэтому НО часто формулируют для них

Guardrails

ограничители: чему нельзя ухудшиться, пока растим таргет

Информативные

продуктовый контекст — что еще изменилось в поведении (срезы по категориям); не принимают участия в решении

Диагностики / debug

проверка: дошло ли воздействие и работает ли как задумано (доставка пушей, показы фичи, ошибки)

Качества данных

валидность самого эксперимента: сплит, логирование

Правила выбора: таргет и драйверы

Таргет

- Понятность
- Устойчивость

Часто таргет недостижим за срок теста — тогда решение принимается по драйверам, а таргет остается ориентиром

Драйверы

- Сонаправленность с таргетом
- Управляемость
- Чувствительность
- **Устойчивость к манипуляциям**

Вырастить метрику, ухудшив продукт

Задача: Команда поиска улучшает выдачу.

Кандидаты в ОЕС: клики на выдаче, время на странице, число поисковых запросов на пользователя. Все три оценивают вовлеченность.

Клики на выдаче

Растут, когда выдача плохая: пользователь не нашел то, что нужно, с первого раза и кликает дальше

Время на странице

Растет при запутанном интерфейсе

Запросы на пользователя

Растет, когда результаты поиска не релевантны, и пользователь переформулирует запрос

Решение: число сессий на пользователя и метрики успеха (конверсия в целевое действие)

Роль в эксперименте и приоритет на уровне компании — разные вещи

GMV

P0 — всегда

приоритет живет в метрическом слое компании и не зависит от того, что мы тестируем

Тест рекомендаций

таргет

ради него эксперимент, решение принимается по этой метрике

Ужесточение антифрода **guardrail**

ложные блокировки могут уронить

Дизайн кабинета продавца информативная

наблюдаем для контекста, но этап находится далеко от точки влияния на метрику

- 1 Роль назначается на время теста, приоритет существует постоянно: таргет не значит «важная метрика», а P3-метрика имеет полное право быть таргетом эксперимента
- 2 Приоритет диктует обязанность: P0 входит в сет любого теста — компания не может не знать, что эксперимент уронил выручку
- 3 Приоритет определяет полномочия: порог по guardrail-у, охраняющему P1 соседней команды, устанавливает команда владелец

Соберем метрик-сет

Push о брошенной корзине в e-commerce

GMV per User

Delivery Rate пушей

CR Cart to Purchase

Uninstall Rate

Orders per User

AOV

Unsubscribe Rate

Balance Test/Control

CTR пуша

Orders per User by Category

Роли: таргет · драйвер · информативная · guardrail · debug · качества данных

Метрик-сет эксперимента с push-уведомлением

Таргет

GMV per User, Orders per User

Драйвер

CR from Cart to Purchase

Guardrails

Unsubscribe Rate, Uninstall Rate

Информативные

AOV, CTR пуша, Orders per User by Category

Debug

Delivery Rate

Data quality

Balance Test / Control

Множественное тестирование

Каждая метрика в сете — отдельный тест с шансом α на ложное срабатывание. Вероятность хотя бы одного ложного эффекта на m независимых метриках: $1 - (1 - \alpha)^m$. При $\alpha = 0.05$ и 10 метриках — уже ~40%.

Bonferroni

α/m на число попарных сравнений: просто, консервативно, стандарт для небольших сетов. 5 ключевых метрик $\rightarrow \alpha = 0.01$

Holm

сортируем p-value по возрастанию, первое сравниваем с α/m , второе с $\alpha/(m-1)$ и т.д., останавливаемся на первом незначимом

Дисциплина сета

лучшая поправка — не добавлять метрику без роли: каждая лишняя размывает α всех остальных

Две угрозы: сломанный сплит и сетевой эффект

Sample Ratio Mismatch (SRM)

фактический сплит != задизайненного

- Ждали 50/50, получили 50.2/49.8 на миллионах — это сломанный эксперимент
- Причины: баг рандомизации, боты в одной группе, потеря событий одной платформы

Ловится числом: χ^2 -тест на равенство долей.

Правило: SRM найден — чиним причину и перезапускаем, результаты не валидны

Сетевой эффект — нарушение SUTVA

исход юнита зависит от другой группы

- Соцграф: тест активнее постит → друзья в контроле видят больше → контроль зааффецчен
- Общий ресурс: фича подняла спрос в тесте → тестовые забрали водителей → в контроле выросли отмены

Эффект измеряется за счет каннибализации контроля и исчезает при раскатке на 100%

Лечится только дизайном — свитчбек, гео

Пять исходов эксперимента

Все ключевые метрики значимы в одну сторону

катим / не катим — легкий случай

Значима одна, эффект положительный

катим

Значима одна, эффект отрицательный

не катим

Ничего не значимо

не катим, думаем о перезапуске

Часть в плюс, часть в минус

**трейд-офф — решение людей,
не статистики**

Трейд-офф можно зашить в формулу

$$\text{ОЕС} = (\Delta \text{Revenue} - s \times \text{Unsubscribe_lifetime_loss}) / N$$

$\Delta \text{Revenue}$ — дополнительная выручка теста относительно контроля

s — число дополнительных отписок в тесте

$\text{unsubscribe_lifetime_loss}$ — выручка, потерянная навсегда: человеку больше нельзя написать

N — пользователей в группе

- Пример Amazon для email-кампаний: инкрементальная выручка письма минус пожизненная цена каждой отписки
- Кампании, «продающие» ценой выжигания базы, получают отрицательную ОЕС автоматически — трейд-офф решен до спора
- **Цена отписки — оценка с допущениями; взвешенная ОЕС не устраняет оценочный характер, а фиксирует его заранее и одинаково для всех тестов**

Что делать, если прокраса таргета не дождаться?

Как выбрать краткосрочную метрику, которой можно доверить долгосрочное решение.

Определение и требования

Прокси-метрика — краткосрочный индикатор, предсказывающий долгосрочный эффект таргет-метрики.

Чувствительность

детектирует стат. значимый эффект за срок теста — иначе зачем она

Сонаправленность (label agreement)

двигается туда же, куда таргет (доказано, на корпусе экспериментов)

Ключевой принцип: связь прокси ↔ таргет оценивается по эффектам в исторических экспериментах, а не по корреляции временных рядов — ряды коррелируют у всего со всем (сезон, рост базы).

Binary Sensitivity

Binary Sensitivity — доля экспериментов, в которых метрика показала статистически значимый эффект.

$$\text{Binary Sensitivity}(\text{metric}) = \frac{|\{\text{experiments where metric is significant}\}|}{|\{\text{all experiments}\}|}$$

- Считается для каждого кандидата в прокси — и для таргета: сравниваем, насколько чаще прокси прокрашивается
- Хорошая прокси значима заметно чаще таргета — иначе она не решает проблему длительности
- **Ничего не говорит о направлении: метрика может быть чувствительной и врать о знаке — поэтому одной проверки чувствительности недостаточно**

MSE и корреляция эффектов

MSE

$MSE = \text{mean}(\Delta_{\text{proxy}_i} - \Delta_{\text{target}_i})^2$
по экспериментам i , на относительных
эффектах

Насколько прокси промахивается
по величине эффекта. Меньше — ближе;
только в комплексе с другими проверками.

Корреляция

$r = \text{corr}(\Delta_{\text{proxy}_i}, \Delta_{\text{target}_i})$
Пирсон по парам эффектов; можно
ранговую

Сила и направление связи эффектов. Высокая
корреляция при высокой Binary Sensitivity —
сильный кандидат.

Почему по эффектам, а не по рядам? Сравнение по рядам — главная ошибка на практике

Дневные ряды «просмотры карточек» и «заявки» коррелируют — оба растут с базой и имеют сезонность. Это ничего не говорит о том, потянет ли рост просмотров рост заявок. Корпус экспериментов — единственный источник причинных пар $(\Delta_{\text{proxy}}, \Delta_{\text{target}})$: каждый тест — точка, где мы знаем, что двигали и что сдвинулось.

Proxy Score

Proxy Score показывает, насколько прокси-метрика согласуется с целевой метрикой в исторических экспериментах.

$$\text{Proxy Score} = \frac{\text{Detections} - \text{Mistakes}}{\#\{\text{experiments where target is significant}\}}$$

- Рассчитывается попарно для каждой прокси и таргета
- Detections — прокси и таргет значимы и сонаправлены;
Mistakes — прокси значима, но направление противоположно таргету
- Диапазон от -1 до 1: ближе к 1 — прокси надежно повторяет таргет; отрицательный — систематически врет о знаке

Матрица знаков

Матрица согласия-несогласия знаков — это вспомогательный инструмент. Она визуализирует совпадения / расхождения по знаку эффекта в исторических экспериментах.

		North Star Metric			
		Long-Term Effect			
Proxy Metric	Short-Term Effect		negative	neutral	positive
		negative	34	203	3
		neutral	15	571	5
		positive	0	93	76

Принятие решения и предостережения

Решение

- Оценка сразу по всем проверкам: Binary Sensitivity + MSE/корреляция + Proxy Score
- Проверки согласуются → кандидат; противоречат → прокси ненадежна, каким бы ни был любой отдельный балл
- Выбранная прокси фиксируется в дизайне до эксперимента, не после

Предостережения

- Убедитесь, что прокси вообще нужна: сначала — улучшить дизайн и чувствительность
- Здравый смысл обязателен: числовые проверки не заменяют причинную историю «почему метрика тянет таргет»
- **Прокси, ставшая критерием раскатки, может быть оптимизирована в обход таргета. Валидируйте и мониторьте связь регулярно**

Эксперимент отвечает на вопрос о целевой метрике

Метрик-сет

шесть ролей; каждая лишняя метрика стоит α всем остальным

ОЕС

одно число решения; трейд-оффы можно взвесить заранее

Прокси

краткосрочный представитель таргета — с доверием, доказанным на корпусе тестов