

Курс «Продуктовые метрики» • Лекция 4

Мониторинг метрик и детекция аномалий

Про что говорили на прошлой неделе

A/B ловит эффект наших изменений, но метрики меняются и без нас

Лекция 3: шесть ролей метрик в экспериментах — таргет, драйверы, guardrails, информативные, диагностики, качества данных. Для нечувствительного таргета подбираем прокси по чувствительности и направленности.

Семинары недели 3: дизайн задается единицей рандомизации, она в свою очередь влияет на типы метрик, с которыми придется работать при расчете длительности и подведении результатов

Сегодня разберемся, как замечать изменения метрик без контрольной группы — каждый день и на всех метриках сразу.

Зачем нужен мониторинг?

Что дает бизнесу:

- предотвращает финансовые потери;
- защищает пользовательский опыт;
- отделяет реальные изменения от внешних факторов (праздники, парсинг, маркетинговые активности)

Какие задачи решает:

- мониторинг активности пользователей;
- поиск ошибок после релизов;
- фильтрация искусственных аномалий

Временные ряды

Метрика в динамике — это временной ряд

Из каких компонент состоит ряд, что считать нормой и какие бывают аномалии.

Основные понятия


Временной ряд — последовательность значений изменяющегося во времени признака, собранных и упорядоченных через равные промежутки времени.

Компоненты:

Тренд — долгосрочная тенденция.



Сезонность — циклические изменения с постоянным периодом.

Ошибки — непрогнозируемые изменения без конкретного паттерна.



Что такое аномалия?

Аномалия — необычное, несвойственное поведение временного ряда.




Как замечать аномалии по мере поступления данных

Контрольные карты, CUSUM, EWMA, 3σ

С чего все началось?

Контрольные карты Шухарта — первый формализованный инструмент онлайн-мониторинга процессов (часть Statistical Process Control).



- Center line — среднее значение наблюдаемой характеристики
- Upper control limit и Lower control limit — допустимая вариация значения вокруг среднего, в рамках которой значение не считается аномальным

Статистика за контрольными картами

$$UCL = \mu_w + L \cdot \sigma_w$$

$$Center\ Line = \mu_w$$

$$LCL = \mu_w - L \cdot \sigma_w$$

- $L=3$ (3σ) — лимиты действия
- $L=2$ (2σ) — лимиты предупреждения

Для среднего

$$UCL = \bar{X} + 3 \cdot \frac{\sigma}{\sqrt{n}}$$

$$CL = \bar{X}$$


$$LCL = \bar{X} - 3 \cdot \frac{\sigma}{\sqrt{n}}$$

Для доли

$$UCL = p + 3 \cdot \sqrt{\frac{p(1-p)}{n}}$$

$$CL = p$$

$$LCL = p - 3 \cdot \sqrt{\frac{p(1-p)}{n}}$$



CUSUM — накопленные сдвиги

CUSUM копит отклонения от ожидаемого среднего μ , отдельно вверх и вниз


$$C_t^+ = \max\{0, C_{t-1}^+ + (x_t - \mu - k)\}$$

$$C_t^- = \max\{0, C_{t-1}^- + (\mu - x_t - k)\}$$

k — референсное отклонение (обычно половина сдвига, который хотим ловить);
 h — порог, баланс ложных тревог и скорости.

Сигнал тревоги:

$$C_t^+ \geq h \quad \text{или} \quad C_t^- \geq h$$



EWMA — сглаженное значение

EWMA (Exponentially Weighted Moving Average) — еще один способ проверки накопленных сдвигов, вместо суммы отклонений следим за экспоненциально взвешенным средним.

$$z_t = \lambda x_t + (1 - \lambda)z_{t-1}, \quad 0 < \lambda \leq 1$$

$\lambda = 1$ — карта Шухарта


$\lambda = 0.05\text{--}0.25$ — чувствительность к малым сдвигам.

Границы сужаются при асимптотическом приближении:

$$UCL_t = \mu + L \cdot \sigma \sqrt{\frac{\lambda}{2 - \lambda} (1 - (1 - \lambda)^{2t})}$$

$$LCL_t = \mu - L \cdot \sigma \sqrt{\frac{\lambda}{2 - \lambda} (1 - (1 - \lambda)^{2t})}$$

При больших t : $\sigma_z = \sigma \sqrt{\frac{\lambda}{2 - \lambda}}$



3σ сегодня

Преимущества: интерпретируемая, легко реализуется, не требует поддержки.

Среднее и дисперсия считаются скользящим окном за N последних дней до анализируемой даты.

По уровням

$$\mu_t = \frac{1}{n} \sum_{i=t-n}^{t-1} x_i, \quad \sigma_t = \sqrt{\frac{1}{n-1} \sum_{i=t-n}^{t-1} (x_i - \mu_t)^2}$$

$$UCL_t = \mu_t + 3\sigma_t, \quad LCL_t = \mu_t - 3\sigma_t$$

Окно N = 14–28 дней. Ловит точечные аномалии на стационарных участках; на тренде растет число ложных алертов.

По дельтам


$$\Delta_t = x_t - x_{t-1}$$

$$UCL_t = \mu_{\Delta,t} + 3\sigma_{\Delta,t}, \quad LCL_t = \mu_{\Delta,t} - 3\sigma_{\Delta,t}$$

Разности первого порядка снимают тренд: ряд Δt стационарнее исходного. Ловит резкие скачки, но пропускает медленную деградацию.

Где ломается 3σ : сезонность

Скользящее окно в 28 дней смешивает будни и выходные: σ раздувается разницей между ними, коридор шире любой реальной аномалии.



Способы исключения сезонности:

1) Норма по дню недели. Точка сравнивается со средним по тем же дням недели за K прошлых недель; σ — по остаткам всего окна от дневных средних.

2) Seasonal naive. Точка сравнивается с одной точкой неделю назад: 3σ по ряду разностей $x_t - x_{t-7}$. Убирает и сезонность, и тренд — недельный прирост уходит в среднее разностей.

3) Week-over-week в логарифмах. То же, что 2, но для $\ln x_t - \ln x_{t-7}$: разность превращается в процент. Читается бизнесом как «-12% к прошлой неделе».

Ретроспективный анализ

Как найти выбросы в истории ряда

Тесты Граббса и GESD, STL-разложение, S-H-ESD

Тест Граббса

Ретроспективные тесты применяются к **историческим данным**, когда нужно проверить, является ли отдельное значение (или несколько) статистически аномальным.

Grubbs's test

Проверяет гипотезу, что **самая экстремальная точка** выборки — выброс:

$$G = \max_i \frac{|x_i - \bar{x}|}{s}$$

x_i — значение в выборке,

$\bar{x}$ — среднее,

s — стандартное отклонение по всей выборке, включая проверяемую точку.

Критерий проверки

$$G_{crit} = \frac{(n-1)}{\sqrt{n}} \cdot \sqrt{\frac{t_{\alpha/(2n), n-2}^2}{n-2 + t_{\alpha/(2n), n-2}^2}}$$

n — число наблюдений,

$t_{\alpha/(2n), n-2}$ — квантиль t-распределения,

α — уровень значимости.

Generalized ESD

Generalized ESD (Extreme Studentized Deviate) ищет **до k выбросов**, когда их число заранее неизвестно: на каждом шаге удаляется самая экстремальная точка и пересчитываются $\bar{x}_j$, s_j .

Generalized ESD

$$R_j = \max_i \frac{|x_i - \bar{x}_j|}{s_j}$$

x_j — значение в выборке,

$\bar{x}_j$ — среднее по выборке без ранее удаленных значений

s_j — стандартное отклонение по выборке без ранее удаленных значений, включая проверяемую точку.

Критерий проверки

$$\lambda_j = \frac{(n - j) \cdot t_{p, n-j-1}}{\sqrt{(n - j - 1 + t_{p, n-j-1}^2)(n - j + 1)}}$$

$$p = 1 - \alpha / (2(n - j + 1))$$

n — число наблюдений,

$t_{p, n-j-1}$ — квантиль t-распределения,

α — уровень значимости.

STL-разложение


Seasonal-Trend decomposition using Loess — представляет временной ряд как сумму трех компонентов.

$$x_t = T_t + S_t + R_t$$


T_t — тренд,

S_t — сезонность,

R_t — остатки, шум и выбросы.



STL-разложение: что меняют параметры



- **seasonal = periodic:** одна сезонная форма на весь ряд, дрейф амплитуды уходит в остатки — регулярная форма, которую 3σ примет за аномалии;
- **seasonal = 5:** сезонность подстраивается, остатки чище — но сезонность частично впитала выброс: соседние недели выучили пик, осталась часть отклонения;
- **seasonal = 5, robust = True:** веса биквадратного уравнения обнулили вклад выброса, он вернулся в остатки.

S-H-ESD: как Twitter объединил STL и GESD

Seasonal Hybrid ESD — подход детекции аномалий в метриках Twitter: STL для структуры, Generalized ESD для остатков.

Две модификации делают его гибридным:


1) Медиана вместо loess-тренда. Тренд подтягивается к аномалии и объясняет ее часть: остаток становится меньше и размазывается по соседям. Поэтому вычитается сезонность STL и медиана:

$$R_t = x_t - S_t - \text{median}(x)$$

2) Робастные оценки в ESD. Вместо $\bar{x}$ и s — медиана и MAD, чтобы сами выбросы не раздували знаменатель.

$$R_j = \max_i \frac{|x_i - \text{median}(x)|}{1,4826 \cdot \text{MAD}}$$

$$\text{MAD} = \text{median}_i |x_i - \text{median}(x)|$$



Мониторинг как система

Как превратить детекцию в рабочий процесс

Инфраструктура, разбор после алерта

Инфраструктура мониторинга и детекции

- | | | |
|---|---------------------------|---|
| 1 | Слой данных | event-трекер, DWH; сырые события и справочники |
| 2 | Слой метрик | единые определения формул, срезов и источников; расчеты и агрегации централизованы |
| 3 | Сервис детекции | в реальном времени или батчами применяет методы к рядам из слоя метрик, возвращает флаги и статистики |
| 4 | Хранилище детекций | история расчетов: что, когда, каким методом, с каким порогом; нужно для оценки ложных срабатываний |
| 5 | Алертинг | триггеры и маршрутизация: кому, куда, с каким приоритетом; дедупликация повторных сигналов |

Что происходит после алерта?

Это реально?

- дубли событий, отставание пайплайна, боты и парсеры — проверяются первыми
- сверка с соседями по дереву: упали заказы, а сессии и корзины в порядке — смотрим оплату

Где именно?

- декомпозиция по срезам из семинара 1: платформа, регион, версия, сегмент
- аномалия в одной версии приложения — почти всегда релиз
- равномерна по срезам — внешний фактор или трекинг

Что изменилось?

- календарь релизов, маркетинговые запуски, инциденты
- дата разладки от CUSUM сужает поиск до одного дня
- итог — письменный разбор

Мониторинг отвечает на вопрос «Что считать нормой?»

3σ

одна точка в день против окна истории

Сезонность

сначала вычесть структуру, потом искать аномалию: день недели, лаг 7, логарифм

STL

робастная декомпозиция дает остатки без тренда и сезонности, на них уже работают тесты на выбросы